

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ — ĐHQGHN
VIỆN TRÍ TUỆ NHÂN TẠO



BÁO CÁO KẾT THÚC MÔN HỌC

**BÁO CÁO NGHIÊN CỨU VÀ XÂY DỰNG HỆ THỐNG
KHÔI PHỤC DẤU CÂU TIẾNG VIỆT
BẰNG MÔ HÌNH BILSTM VÀ PHOBERT**

Học phần: Xử lý Ngôn ngữ Tự nhiên (NLP)

Giảng viên hướng dẫn:
TS. Trần Hồng Việt
Trường Đại học Công nghệ

Nhóm thực hiện: Nhóm 7
Nguyễn Quang Sang (MSV: 24022440)
Data & ASR Pipeline
Đỗ Khắc Phúc Thịnh (MSV: 24022458)
Model Training & Tuning
Trần Bùi Hà Giang (MSV: 24022314)
Evaluation & UI Application

Hà Nội, Tháng 08 năm 2026

Lời Cảm Ơn

Lời đầu tiên, nhóm chúng em xin được gửi lời cảm ơn chân thành và sâu sắc nhất tới Tiến sĩ Trần Hồng Việt, giảng viên phụ trách môn học Xử lý Ngôn ngữ Tự nhiên. Trong suốt quá trình học tập và triển khai bài tập lớn này, thầy đã tận tình hướng dẫn, truyền đạt những kiến thức chuyên môn quý báu, định hướng phương pháp luận khoa học đúng đắn và đưa ra những góp ý thiết thực, giúp nhóm hoàn thiện hệ thống một cách tốt nhất.

Nhóm cũng xin gửi lời cảm ơn chân thành tới tập thể các bạn sinh viên trong lớp đã luôn đồng hành, thảo luận, chia sẻ những tài liệu hữu ích và hỗ trợ nhóm trong suốt quá trình hoàn thành bài tập lớn này.

Mặc dù nhóm đã nỗ lực hết mình để xây dựng và thực nghiệm hệ thống một cách cẩn chu, bài bản nhất, song báo cáo khó tránh khỏi những hạn chế nhất định. Nhóm rất mong tiếp tục nhận được những ý kiến đóng góp quý báu từ thầy và các bạn để đề tài ngày càng hoàn thiện hơn.

Chúng em xin chân thành cảm ơn!

Thành viên Nhóm 7

Nguyễn Quang Sang – Đỗ Khắc Phúc Thịnh – Trần Bùi Hà Giang

Mục lục

Lời Cảm Ôn	1
1 Tổng quan và Đặt vấn đề	5
1.1 Bối cảnh nghiên cứu	5
1.2 Mục tiêu của đề tài	5
1.3 Cấu trúc bài báo cáo và Phân công nhân sự	5
2 Kiến trúc Hệ thống và Kiến thức Nền tảng	6
2.1 Cấu trúc mô-đun của hệ thống	6
2.2 Bài toán Gán nhãn Chuỗi (Sequence Labeling)	6
2.3 Các mô hình học sâu áp dụng	7
2.3.1 Mô hình cơ sở: Bidirectional LSTM (BiLSTM)	7
2.3.2 Mô hình ngôn ngữ tiền huấn luyện: PhoBERT	7
3 Xử lý Dữ liệu và Tích hợp ASR	7
3.1 Nguồn dữ liệu và Tiêu chuẩn hóa	7
3.2 Chiến lược Phân đoạn (Chunking Pipeline)	8
3.3 Thống kê Dữ liệu và Phân bố Nhãn	8
3.4 Tích hợp Mô-đun ASR (Whisper ASR Integration)	8
4 Huấn luyện Mô hình và Các Thí nghiệm	8
4.1 Thiết lập Các Thí nghiệm ($E1 - E4$)	9
4.2 Siêu tham số và Cấu hình Huấn luyện	9
4.3 Lưu trữ và Quản lý Checkpoint	9
5 Đánh giá Thực nghiệm, Chọn Mô hình Winner và Phân tích Lỗi	10
5.1 Tiêu chí Đánh giá và Quy trình Khóa Winner	10
5.2 Kết quả So sánh trên Tập Validation và Khóa Winner	10
5.3 Kết quả Đánh giá Official Test của Winner ($E2$)	12
5.4 So sánh Post-hoc giữa các mô hình trên Test	13
5.5 Ma trận nhầm lẫn (Confusion Matrix)	14
5.6 Phân tích Lỗi Chuyên sâu (Error Analysis)	14
6 Module Hậu xử lý và Ứng dụng Demo (Streamlit App)	15

6.1	Thuật toán Hậu xử lý và Viết hoa (Post-processing Pipeline)	15
6.2	Xây dựng Giao diện Demo tương tác Streamlit	16
7	Kết luận và Hướng Phát triển	16
7.1	Kết luận đánh giá	16
7.2	Hạn chế và Hướng phát triển trong tương lai	17

Danh sách bảng

1	Bảng phân công nhiệm vụ chi tiết nhóm 7	6
2	Thống kê chi tiết dữ liệu huấn luyện, kiểm định và kiểm tra	8
3	Bộ siêu tham số huấn luyện cho các mô hình E1–E4	9
4	Kết quả đánh giá so sánh các mô hình trên tập Validation (Selection Protocol)	10
5	Báo cáo hiệu năng chi tiết từng lớp dấu câu của Winner (E2) trên Official Test	12
6	Bảng so sánh Post-hoc hiệu năng các mô hình trên tập Test chính thức	13
7	Ma trận nhầm lẫn (Confusion Matrix) của Winner E2 trên tập Test	14
8	Trích xuất 10 trường hợp lỗi điển hình và quan sát giải thích	15

Danh sách hình vẽ

1	Sơ đồ pipeline ứng dụng của hệ thống. Đánh giá định lượng chính trong báo cáo được thực hiện trên đầu vào văn bản JointCapPunc.	6
2	Biểu đồ so sánh chỉ số Punctuation Macro-F1 giữa 4 mô hình trên tập Validation và việc quyết định Winner E2	11
3	Biểu đồ phân tích tác động của các chế độ Class Weight tới chỉ số F1 từng lớp dấu câu trên tập Validation	11
4	Biểu đồ cột F1 từng lớp dấu câu của Winner E2 giữa Validation và Official Test	12
5	So sánh Post-hoc giữa 4 mô hình huấn luyện trên Official Test	13
6	Ma trận nhầm lẫn theo số lượng mẫu thực tế và theo tỷ lệ phần trăm chuẩn hóa (%) của Winner E2	14
7	Minh họa hoạt động khôi phục dấu câu trên giao diện Demo Streamlit	16

1. Tổng quan và Đặt vấn đề

1.1. Bối cảnh nghiên cứu

Trong kỷ nguyên bùng nổ của trí tuệ nhân tạo và các ứng dụng chuyển đổi giọng nói thành văn bản (Automatic Speech Recognition - ASR), hệ thống ASR đóng vai trò cầu nối quan trọng giữa giao tiếp tự nhiên của con người và hệ thống xử lý dữ liệu của máy tính. Tuy nhiên, các mô hình ASR tiên tiến hiện nay (như OpenAI Whisper, Kaldi, Wav2Vec 2.0) thường tập trung tối ưu chỉ số nhận dạng từ (Word Error Rate - WER) mà bỏ qua hoặc tạo ra văn bản thô không chứa dấu câu và viết hoa.

Văn bản thô thiếu dấu câu gây ra nhiều khó khăn đáng kể:

- **Suy giảm khả năng đọc hiểu (Readability):** Con người gặp rất nhiều khó khăn khi đọc một văn bản dài không có điểm dừng, không phân biệt câu khẳng định, câu hỏi hay đoạn liệt kê.
- **Ảnh hưởng tiêu cực đến các tác vụ NLP hạ nguồn (Downstream Tasks):** Các hệ thống như Dịch máy (Machine Translation), Tóm tắt văn bản (Text Summarization), Trích xuất thông tin (Information Extraction) hay Phân tích quan điểm (Sentiment Analysis) đều phụ thuộc chặt chẽ vào ranh giới câu để xác định cấu trúc ngữ pháp.
- **Biến đổi nghĩa nghiêm trọng:** Trong tiếng Việt, việc thiếu dấu phẩy hoặc dấu chấm có thể làm thay đổi hoàn toàn ngữ nghĩa ngữ pháp của câu.

1.2. Mục tiêu của đề tài

Đề tài hướng tới việc xây dựng và đánh giá một hệ thống khôi phục dấu câu tự động cho văn bản tiếng Việt với các mục tiêu chính:

1. Khôi phục ba loại dấu câu gồm **COMMA (,)**, **PERIOD (.)** và **QUESTION (?)** dưới dạng bài toán gắn nhãn chuỗi.
2. Xây dựng và so sánh bốn thiết lập mô hình gồm **BiLSTM baseline** và **PhoBERT** với các **chiến lược xử lý class weighting khác nhau**, sử dụng Punctuation Macro-F1 trên tập Validation làm chỉ số chính để lựa chọn mô hình.
3. Tích hợp mô-đun **Whisper ASR** và mô-đun hậu xử lý vào pipeline ứng dụng, đồng thời xây dựng giao diện Streamlit để minh họa khả năng sử dụng hệ thống.

Trong đó, **đánh giá định lượng chính của mô hình khôi phục dấu câu được thực hiện trên dữ liệu văn bản JointCapPunc**. Việc đánh giá end-to-end từ audio qua ASR đến khôi phục dấu câu chưa được thực hiện trong phạm vi các thực nghiệm được báo cáo.

1.3. Cấu trúc bài báo cáo và Phân công nhân sự

Báo cáo được cấu trúc thành 7 phần chính, phản ánh quy trình phát triển dự án thực tế và phân công công việc chi tiết cho 3 thành viên:

Bảng 1: Bảng phân công nhiệm vụ chi tiết nhóm 7

Thành viên	Vai trò kỹ thuật	Nhiệm vụ cụ thể
Nguyễn Quang Sang (MSV: 24022440)	Data & ASR Layer	Thu thập dataset JointCapPunc, làm sạch Unicode NFC, tạo nhãn dấu câu, chunking 150 words, tích hợp module Whisper ASR và tính toán data statistics.
Đỗ Khắc Phúc Thịnh (MSV: 24022458)	Model & Training Layer	Xây dựng mô hình BiLSTM baseline, PhoBERT Token Classification, xử lý sub-word alignment (-100), cài đặt Loss Weighting (Inverse & Sqrt-Inverse), chạy thí nghiệm $E1-E4$.
Trần Bùi Hà Giang (MSV: 24022314)	Evaluation & App Layer	Viết framework đánh giá, tính Punctuation Macro-F1, chọn và khóa Winner, phân tích lỗi (30 error cases), xây dựng module hậu xử lý, viết Streamlit UI và tổng hợp báo cáo.

2. Kiến trúc Hệ thống và Kiến thức Nền tảng

2.1. Cấu trúc mô-đun của hệ thống

Hệ thống được thiết kế theo kiến trúc phân lớp (Layered Architecture) nhằm đảm bảo tính mô-đun hóa, dễ dàng mở rộng và thử nghiệm độc lập. Sơ đồ pipeline ứng dụng của hệ thống được mô tả trong Hình 1.



Hình 1: Sơ đồ pipeline ứng dụng của hệ thống. Đánh giá định lượng chính trong báo cáo được thực hiện trên đầu vào văn bản JointCapPunc.

2.2. Bài toán Gán nhãn Chuỗi (Sequence Labeling)

Khôi phục dấu câu được phát biểu dưới dạng bài toán gán nhãn chuỗi theo từng từ (Word-level Sequence Labeling). Cho một chuỗi các từ đầu vào không có dấu câu $X = (x_1, x_2, \dots, x_N)$, mục tiêu của mô hình là dự đoán một chuỗi các nhãn $Y = (y_1, y_2, \dots, y_N)$, trong đó $y_i \in \mathcal{L} = \{\text{O}, \text{COMMA}, \text{PERIOD}, \text{QUESTION}\}$.

$$y_i = \begin{cases} \text{O} & \text{Không có dấu câu sau từ } x_i \\ \text{COMMA} & \text{Dấu phẩy (,) xuất hiện liền sau từ } x_i \\ \text{PERIOD} & \text{Dấu chấm (.) xuất hiện liền sau từ } x_i \\ \text{QUESTION} & \text{Dấu hỏi (?) xuất hiện liền sau từ } x_i \end{cases} \quad (1)$$

2.3. Các mô hình học sâu áp dụng

2.3.1. Mô hình cơ sở: Bidirectional LSTM (BiLSTM)

Mạng Long Short-Term Memory hai chiều (BiLSTM) cho phép ghi nhận thông tin ngữ cảnh từ cả hai hướng quá khứ và tương lai của chuỗi từ. Kiến trúc bao gồm một lớp Embedding (chiều $D = 128$), theo sau bởi một lớp BiLSTM 2 chiều ($H = 128$ mỗi chiều, tổng 256), Dropout ($p = 0.3$) và lớp tuyến tính Dense để chiếu ra không gian 4 nhãn.

2.3.2. Mô hình ngôn ngữ tiền huấn luyện: PhoBERT

PhoBERT [1] là mô hình Transformer mã hóa dựa trên kiến trúc RoBERTa, được huấn luyện trên tập dữ liệu tiếng Việt đồ sộ (20GB văn bản). PhoBERT sử dụng Byte-Pair Encoding (BPE) để phân tách từ thành các subword.

Do PhoBERT hoạt động ở mức subword, dự án áp dụng quy tắc **Last-Subword Alignment**: Nhãn dấu câu thực tế của một từ sẽ được gán cho subword cuối cùng của từ đó, trong khi các subword đầu và giữa sẽ nhận giá trị nhãn đặc biệt là -100 để bỏ qua khi tính toán Cross-Entropy Loss.

3. Xử lý Dữ liệu và Tích hợp ASR

3.1. Nguồn dữ liệu và Tiêu chuẩn hóa

Dự án sử dụng tập dữ liệu chuẩn **JointCapPunc** [4], được cố định tại commit SHA `ee258cae0e95e64245428d59ebbb030280fcebce`. Dữ liệu thô ban đầu ở định dạng TSV với 3 trường thông tin: `token`, `capitalization_label`, `punctuation_label`.

Quy trình làm sạch và chuẩn hóa dữ liệu bao gồm các bước:

1. Chuẩn hóa Unicode tiếng Việt về dạng dựng sẵn **NFC**.
2. Bảo toàn hoàn toàn dấu thanh tiếng Việt và cấu trúc từ phức.
3. Ánh xạ bộ nhãn dấu câu nguyên bản về 4 nhãn tiêu chuẩn của dự án: **QMARK** $\rightarrow$ **QUESTION**.
4. Loại bỏ các mẫu trùng lặp hoàn toàn (exact normalized duplicates) trong từng tập split.

3.2. Chiến lược Phân đoạn (Chunking Pipeline)

Do độ dài của các mẫu văn bản có sự biến thiên lớn, dự án áp dụng chiến lược chia đoạn với độ dài tối đa **150 lexical words** và ưu tiên ngắt tại các ranh giới kết thúc câu tự nhiên như **PERIOD** hoặc **QUESTION**.

Việc ánh xạ giữa chuỗi từ và chuỗi nhãn được duy trì trong quá trình chunking. Tuy nhiên, do PhoBERT sử dụng giới hạn **192 subwords**, số lượng lexical words không tương đương trực tiếp với số lượng subwords sau tokenization.

[CẦN XÁC MINH] Báo cáo hiện chưa có thống kê về số mẫu sau tokenization vượt quá 192 subwords cũng như tỷ lệ mẫu phải truncate. Do đó, chưa đủ cơ sở để khẳng định rằng tất cả các sample 150 words đều được biểu diễn đầy đủ trong giới hạn 192 subwords.

Đối với vấn đề rò rỉ dữ liệu, dự án đã loại bỏ các exact normalized duplicates trong từng split. Việc kiểm tra duplicate giữa các cặp Train-Validation, Train-Test và Validation-Test chưa được xác nhận trong thực nghiệm hiện tại.

3.3. Thống kê Dữ liệu và Phân bố Nhãn

Sau khi thực hiện quy trình xử lý, toàn bộ dữ liệu được chia theo tỷ lệ phân chia gốc (Official Split) nhằm đảm bảo tính khách quan và khả năng so sánh đối sánh. Bảng 2 tổng hợp các chỉ số thống kê chi tiết của 3 tập dữ liệu.

Bảng 2: Thống kê chi tiết dữ liệu huấn luyện, kiểm định và kiểm tra

Tập dữ liệu	Số câu (Sample)	Tổng số Token	O (%)	COMMA (%)	PERIOD (%)	QUESTION (%)
Train	38,066	4,940,478	91.10%	4.62%	3.73%	0.56%
Validation	15,227	1,977,406	91.06%	4.64%	3.74%	0.56%
Test	22,832	2,968,815	91.04%	4.64%	3.76%	0.56%

Nhận xét dữ liệu: Dữ liệu thể hiện sự mất cân bằng lớp nghiêm trọng. Nhãn không có dấu câu (O) chiếm khoảng **91.1%** tổng số token, trong khi nhãn **QUESTION** chỉ chiếm khoảng **0.56%**. Do đó, Accuracy không được sử dụng làm chỉ số chính để lựa chọn mô hình; thay vào đó, Punctuation Macro-F1 trên ba nhãn dấu câu được sử dụng làm tiêu chí chính.

3.4. Tích hợp Mô-đun ASR (Whisper ASR Integration)

Nguyễn Quang Sang tích hợp mô hình OpenAI Whisper (**whisper-base**) [5] làm module hỗ trợ chuyển đổi tệp âm thanh tiếng Việt thành văn bản thô. Văn bản đầu ra từ Whisper sẽ được tự động loại bỏ các dấu câu cũ, đưa về dạng chữ thường để làm đầu vào cho mô hình khôi phục dấu câu.

4. Huấn luyện Mô hình và Các Thí nghiệm

4.1. Thiết lập Các Thí nghiệm (E1 – E4)

Đỗ Khắc Phúc Thịnh tiến hành xây dựng và huấn luyện 4 thiết lập mô hình độc lập nhằm so sánh hiệu năng và lựa chọn mô hình có Punctuation Macro-F1 cao nhất trong phạm vi các cấu hình được thử nghiệm:

- **E1 (BiLSTM Baseline):** Sử dụng từ điển từ đơn lẻ (Vocabulary) xây từ tập Train, chuỗi từ chuyển thành Word ID, huấn luyện với Cross-Entropy không trọng số.
- **E2 (PhoBERT No-Weight):** Sử dụng PhoBERT-base-v2, tối ưu bằng Cross-Entropy cơ bản.
- **E3 (PhoBERT Full Inverse Weight):** Tích hợp trọng số nghịch đảo tần suất lớp

$$W_c = \frac{N_{total}}{K \cdot N_c}$$

vào hàm mất mát nhằm tăng mức đóng góp của các lớp có tần suất thấp.

- **E4 (PhoBERT Sqrt-Inverse Weight):** Sử dụng trọng số căn bậc hai nghịch đảo

$$W_c = \sqrt{\frac{N_{total}}{K \cdot N_c}}$$

nhằm làm giảm độ lớn của trọng số so với chiến lược inverse weighting trực tiếp.

4.2. Siêu tham số và Cấu hình Huấn luyện

Tất cả các mô hình Transformer được huấn luyện trên GPU NVIDIA với Mixed Precision (FP16). Bảng 3 tóm tắt bộ siêu tham số chi tiết.

Bảng 3: Bộ siêu tham số huấn luyện cho các mô hình E1–E4

Siêu tham số	E1 (BiLSTM)	E2 (PhoBERT)	E3 (PhoBERT Inv)	E4 (PhoBERT Sqrt)
Architectural Base	BiLSTM 2-layer	PhoBERT-base-v2	PhoBERT-base-v2	PhoBERT-base-v2
Max Seq Length	150 words	192 subwords	192 subwords	192 subwords
Batch Size (Effective)	128	16 (4x4 accumulation)	16	16
Optimizer	AdamW	AdamW	AdamW	AdamW
Learning Rate	1×10^{-3}	3×10^{-5}	3×10^{-5}	3×10^{-5}
Weight Decay	1×10^{-4}	0.01	0.01	0.01
Warmup Ratio	–	0.10	0.10	0.10
Loss Function	CrossEntropy	Standard CE	Weighted CE (Full)	Weighted CE (Sqrt)
Total Epochs	12	5	5	5

4.3. Lưu trữ và Quản lý Checkpoint

Trong suốt quá trình huấn luyện, mô hình được kiểm tra liên tục trên tập Validation sau mỗi Epoch. Chỉ có Checkpoint đạt chỉ số **Validation Punctuation Macro-F1** cao nhất mới được ghi đè vào thư mục `outputs/checkpoints/E{i}/`.

5. Đánh giá Thử nghiệm, Chọn Mô hình Winner và Phân tích Lỗi

5.1. Tiêu chí Đánh giá và Quy trình Khóa Winner

Nhằm hạn chế nguy cơ rò rỉ thông tin từ tập Test vào quá trình lựa chọn mô hình, quy trình lựa chọn Winner được thực hiện dựa trên tập Validation theo các bước:

1. Đọc toàn bộ kết quả Validation của bốn thí nghiệm E1, E2, E3 và E4.
2. So sánh dựa trên chỉ số chính: **Punctuation Macro-F1**, được tính bằng trung bình cộng F1-score của ba nhãn dấu câu COMMA, PERIOD và QUESTION, không tính nhãn O.
3. Lựa chọn mô hình có Punctuation Macro-F1 cao nhất trên Validation, ghi nhận vào file cấu hình `outputs/evaluation/model_selection.json` và khóa **Winner**.
4. Sau khi Winner được khóa, mô hình Winner được sử dụng cho **primary evaluation trên Official Test**. Kết quả Test của Winner được xem là kết quả đánh giá chính của hệ thống.
5. Các mô hình còn lại có thể được đánh giá trên Official Test dưới dạng **post-hoc evaluation** nhằm phục vụ phân tích và so sánh sau thử nghiệm. Các kết quả post-hoc này **không được sử dụng để lựa chọn Winner**.


5.2. Kết quả So sánh trên Tập Validation và Khóa Winner

Bảng 4 thể hiện kết quả so sánh trên tập kiểm định (Validation Set).


Bảng 4: Kết quả đánh giá so sánh các mô hình trên tập Validation (Selection Protocol)

Mã EXP	Mô hình	Class Weight	Best Epoch	Val Loss	Val Accuracy	Val Punct-F1
E2	PhoBERT-base-v2	None	5	0.1021	0.9667	0.7787
E4	PhoBERT-base-v2	Sqrt-Inverse	5	0.1245	0.9572	0.7457
E3	PhoBERT-base-v2	Full-Inverse	5	0.1892	0.9358	0.6953
E1	BiLSTM Baseline	None	11	0.1654	0.9448	0.6282

Lưu ý về Best Epoch: Đối với các mô hình PhoBERT E2–E4, Best Epoch đều bằng 5, tương ứng với epoch cuối cùng trong phạm vi 5 epoch được thử nghiệm. Do đó, kết quả này chỉ cho biết checkpoint tốt nhất trong phạm vi thí nghiệm đã thực hiện, không đủ cơ sở để kết luận rằng mô hình đã hội tụ hoàn toàn.



Hình 2: Biểu đồ so sánh chỉ số Punctuation Macro-F1 giữa 4 mô hình trên tập Validation và việc quyết định Winner E2



Hình 3: Biểu đồ phân tích tác động của các chế độ Class Weight tới chỉ số F1 từng lớp dấu câu trên tập Validation

Lựa chọn Winner: Như minh họa trong Hình 2 và Hình 3, mô hình **E2 (PhoBERT không dùng class weight)** đạt Punctuation Macro-F1 cao nhất trong bốn thiết lập trên tập Validation, với giá trị **0.7787**. Do đó, E2 được lựa chọn và khóa làm **Winner** của hệ thống.


5.3. Kết quả Đánh giá Official Test của Winner (E2)

Sau khi khóa Winner dựa trên tập Validation, mô hình E2 được sử dụng cho **primary evaluation trên Official Test** gồm 2,968,815 token. Kết quả chi tiết theo từng lớp được trình bày trong Bảng 5 và Hình 4.

Bảng 5: Báo cáo hiệu năng chi tiết từng lớp dấu câu của Winner (E2) trên Official Test

Nhãn Dấu câu	Precision	Recall	F1-Score	Support (Số mẫu)
COMMA (,)	0.7407	0.7054	0.7226	137,612
PERIOD (.)	0.7948	0.8240	0.8091	111,606
QUESTION (?)	0.7484	0.8528	0.7972	16,718
Tổng kết hiệu năng				
Punctuation Macro-F1			0.7763	—
Macro-F1 (Tất cả 4 lớp)			0.8288	—
Overall Accuracy			0.9663	2,968,815

Nhận xét: Trên Official Test, E2 đạt Punctuation Macro-F1 = **0.7763**. Trong ba loại dấu câu, PERIOD đạt F1 cao nhất với **0.8091**, tiếp theo là QUESTION với **0.7972** và COMMA với **0.7226**. Kết quả cho thấy mô hình có khả năng nhận diện cả ba loại dấu câu, tuy nhiên việc dự đoán COMMA vẫn khó hơn tương đối so với PERIOD và QUESTION trong thiết lập hiện tại.



Hình 4: Biểu đồ cột F1 từng lớp dấu câu của Winner E2 giữa Validation và Official Test


5.4. So sánh Post-hoc giữa các mô hình trên Test

Sau khi E2 được khóa làm Winner dựa trên tập Validation, kết quả của E1, E3 và E4 trên Official Test được trình bày dưới dạng **post-hoc evaluation**. Mục đích của phân tích này là cung cấp thêm góc nhìn so sánh về hiệu năng giữa các thiết lập đã được huấn luyện.

Các kết quả post-hoc này được báo cáo **chỉ nhằm mục đích phân tích sau thực nghiệm và không được sử dụng để lựa chọn Winner**.

Bảng 6: Bảng so sánh Post-hoc hiệu năng các mô hình trên tập Test chính thức

Mô hình	F1 COMMA	F1 PERIOD	F1 QUESTION	Punct-F1	Accuracy	Size (MB)
E2 (PhoBERT None)	0.7226	0.8091	0.7972	0.7763	0.9663	514.7
E4 (PhoBERT Sqrt-Inv)	0.6972	0.7887	0.7456	0.7438	0.9568	514.7
E3 (PhoBERT Full-Inv)	0.6107	0.7569	0.7168	0.6948	0.9355	514.7
E1 (BiLSTM Baseline)	0.4893	0.6837	0.7008	0.6246	0.9442	16.9



Hình 5: So sánh Post-hoc giữa 4 mô hình huấn luyện trên Official Test

Nhận xét về E1 và E2: Trên Official Test, E2 (PhoBERT) đạt Punctuation Macro-F1 = **0.7763**, cao hơn E1 (BiLSTM) với Punctuation Macro-F1 = **0.6246**. Kết quả này cho thấy E2 đạt hiệu năng cao hơn E1 trong thiết lập thực nghiệm của dự án.

Tuy nhiên, sự khác biệt về hiệu năng không thể được quy hoàn toàn cho kiến trúc Transformer. E1 sử dụng BiLSTM được huấn luyện từ đầu, trong khi E2 sử dụng PhoBERT là mô hình ngôn ngữ đã được tiền huấn luyện. Vì vậy, chênh lệch quan sát được có thể đồng thời phản ánh sự khác biệt về kiến trúc và lợi ích từ quá trình pretraining.


Do đó, thực nghiệm hiện tại cho phép kết luận rằng **E2 là mô hình có hiệu năng cao nhất trong các thiết lập được thử nghiệm**, nhưng chưa đủ để tách biệt riêng rẽ ảnh hưởng của kiến trúc Transformer và pretraining.

5.5. Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn của mô hình Winner E2 trên tập Test được trình bày trong Bảng 7 và minh họa trực quan trong Hình 6.

Bảng 7: Ma trận nhầm lẫn (Confusion Matrix) của Winner E2 trên tập Test

Thực tế (Gold)	Dự đoán (Predicted)			
	O	COMMA	PERIOD	QUESTION
O	2,665,368	24,647	10,936	1,928
COMMA	27,483	97,069	12,034	1,026
PERIOD	8,789	9,012	91,967	1,838
QUESTION	1,363	318	780	14,257



Hình 6: Ma trận nhầm lẫn theo số lượng mẫu thực tế và theo tỷ lệ phần trăm chuẩn hóa (%) của Winner E2

5.6. Phân tích Lỗi Chuyên sâu (Error Analysis)

Dựa trên ma trận nhầm lẫn, dự án tiến hành trích xuất và phân tích 30 trường hợp lỗi điển hình. Bảng 8 minh họa 10 trường hợp lỗi được lựa chọn nhằm đại diện cho một số dạng nhầm lẫn quan sát được.

Bảng 8: Trích xuất 10 trường hợp lỗi điển hình và quan sát giải thích

STT	Gold	Pred	Loại lỗi	Ngữ cảnh và Quan sát giải thích
1	COMMA	O	Bỏ sót dấu phẩy	"sách báo thấy mình giống sỏi thận [O] trong khi bs bảo..." → Có thể liên quan đến việc ngữ cảnh cục bộ chưa đủ rõ để xác định vị trí ngắt.
2	O	COMMA	Dấu phẩy thừa	"nhưng nếu bị viêm đường tiết niệu [COMMA] bạn nên..." → Có thể liên quan đến tín hiệu ngắt nghỉ do liên từ.
3	COMMA	PERIOD	Liệt kê nhầm ngắt câu	"trắng đục như nước vo gạo [PERIOD] sau mỗi lần..." → Mô hình dự đoán ranh giới câu sớm trong một ngữ cảnh có tín hiệu chuyển tiếp.
4	O	PERIOD	Cắt câu sớm	"để chứng minh sự việc [PERIOD] tôi thỉnh thoảng..." → Cấu trúc cục bộ có thể tạo tín hiệu tương tự một câu hoàn chỉnh.
5	PERIOD	COMMA	Nối câu liên tiếp	"bạn phải điều trị tích cực ngay [COMMA] nếu để..." → Có thể liên quan đến việc mô hình nhận diện ranh giới giữa các vế phụ thuộc chưa chính xác.
6	QUESTION	PERIOD	Nhầm dấu hỏi/chấm	"bác sĩ cho em hỏi bệnh này có nguy hiểm không [PERIOD]" → Tín hiệu câu hỏi ở cuối đoạn hội thoại có thể chưa đủ rõ đối với mô hình.
7	PERIOD	O	Bỏ sót dấu chấm	"đã chích 2 mũi vaccine covid rồi [O] nhưng không..." → Mô hình có thể nhầm cấu trúc câu dài với một chuỗi liên tục.
8	O	QUESTION	Nhầm dấu hỏi	"xin hỏi bs là tôi [QUESTION] có cần đi khám..." → Mô hình có thể dự đoán dấu hỏi quá sớm sau cụm từ mang tính nghi vấn.
9	COMMA	O	Bỏ sót liệt kê	"mặt ngơ ngác [O] khóc đi qua đi lại..." → Chuỗi hành động ngắn có thể tạo ngữ cảnh khó phân biệt giữa ngắt và không ngắt.
10	PERIOD	COMMA	Ngắt vế dài	"sinh hoạt nhẹ nhàng được [COMMA] với các hoạt động..." → Mô hình có thể nhầm ranh giới giữa dấu chấm và dấu phẩy trong cấu trúc vế bổ trợ.

6. Module Hậu xử lý và Ứng dụng Demo (Streamlit App)

6.1. Thuật toán Hậu xử lý và Viết hoa (Post-processing Pipeline)

Sau khi mô hình đưa ra chuỗi dự đoán nhãn cho từng từ, module `postprocess.py` tiến hành tái tạo văn bản theo các quy tắc khắt khe:

1. Chèn ký tự dấu câu (, , . , ?) liền sau từ tương ứng.

2. Xóa bỏ khoảng trắng thừa trước dấu câu, tự động thêm khoảng trắng chuẩn sau dấu câu.
3. Tự động viết hoa (Capitalization): Viết hoa từ đầu tiên của văn bản, và viết hoa ký tự đầu tiên của từ đứng ngay sau nhãn PERIOD hoặc QUESTION.
4. Bảo toàn nguyên vẹn các cấu trúc đặc biệt: URL, Địa chỉ Email, và Số thập phân (ví dụ: 3.14 không bị tách nhân).

6.2. Xây dựng Giao diện Demo tương tác Streamlit

Ứng dụng Web tương tác được xây dựng bằng framework **Streamlit** (`app/app.py`). Giao diện được thiết kế hiện đại, tự động load Winner từ file cấu hình `model_selection.json` và hỗ trợ bộ ví dụ đầu vào phong phú.

Input (Văn bản thô không dấu): bạn đã hoàn thành bài tập chưa ngày mai chúng ta nộp bài	Restored Output (Sau khôi phục): Bạn đã hoàn thành bài tập chưa? Ngày mai chúng ta nộp bài.
--	--

(a) Giao diện nhập liệu văn bản thô

(b) Kết quả khôi phục dấu câu và viết hoa

Hình 7: Minh họa hoạt động khôi phục dấu câu trên giao diện Demo Streamlit

7. Kết luận và Hướng Phát triển

7.1. Kết luận đánh giá

Dự án đã xây dựng và thực nghiệm một hệ thống khôi phục dấu câu tiếng Việt gồm các thành phần tiền xử lý dữ liệu, mô hình dự đoán, hậu xử lý và giao diện minh họa. Các kết quả chính đạt được bao gồm:

- Mô hình **PhoBERT E2** đạt Punctuation Macro-F1 = **0.7763** trên Official Test, cao hơn BiLSTM baseline E1 với giá trị **0.6246**. Kết quả này cho thấy E2 đạt hiệu năng cao hơn E1 trong thiết lập thực nghiệm của dự án.
- Trên tập Validation, E2 đạt Punctuation Macro-F1 = **0.7787**, cao nhất trong bốn thiết lập E1–E4 và do đó được lựa chọn làm Winner trước khi đánh giá trên Official Test.
- Hai chiến lược Loss Weighting được khảo sát trong E3 và E4 đều không cải thiện Punctuation Macro-F1 so với E2 trong thiết lập thực nghiệm hiện tại. Do các phân tích bổ sung chưa đủ để xác định quan hệ nhân quả, kết quả này được diễn giải là class weighting không mang lại lợi ích trong các cấu hình đã thử nghiệm.
- Hệ thống được đóng gói với pipeline hậu xử lý và giao diện Streamlit. Thử nghiệm nội bộ của nhóm ghi nhận throughput khoảng **77,000 words/sec** trên GPU NVIDIA RTX 3090. Tuy nhiên, thông số này được xem là kết quả đo trong thiết lập thử nghiệm của nhóm và chưa đủ thông tin để sử dụng như một benchmark chuẩn hóa giữa các hệ thống.

- Đánh giá định lượng chính được thực hiện trên dữ liệu văn bản JointCapPunc. Mô-đun Whisper ASR đã được tích hợp vào pipeline ứng dụng, nhưng đánh giá end-to-end từ audio qua ASR đến khôi phục dấu câu chưa được thực hiện.

7.2. Hạn chế và Hướng phát triển trong tương lai

1. **Chưa đánh giá ASR Audio end-to-end:** Hiện tại hệ thống được đánh giá định lượng chủ yếu trên dữ liệu văn bản sạch JointCapPunc. Mặc dù Whisper đã được tích hợp như một mô-đun ASR trong pipeline, dự án chưa thực hiện đánh giá định lượng trực tiếp trên luồng âm thanh thực tế. Trong tương lai, cần kết hợp audio đầu vào với Whisper ASR và mô hình khôi phục dấu câu để đánh giá tác động của lỗi nhận dạng, chẳng hạn như WER, đến hiệu năng khôi phục dấu câu.
2. **Mô hình viết hoa riêng biệt:** Hiện tại dự án sử dụng các luật hậu xử lý để viết hoa. Một hướng phát triển tiếp theo là xây dựng mô hình Joint Capitalization & Punctuation nhằm cải thiện khả năng xử lý tên riêng, địa danh và các cấu trúc đặc biệt.
3. **Kiểm tra giới hạn tokenization:** Do chunking được xác định theo lexical words trong khi PhoBERT xử lý subwords với giới hạn 192 subwords, cần bổ sung thống kê về các mẫu vượt giới hạn sau tokenization và cách xử lý truncate/alignment để đảm bảo tính đầy đủ của quy trình tiền xử lý.
4. **Kiểm tra duplicate giữa các split:** Quy trình hiện tại đã loại bỏ exact normalized duplicates trong từng split. Một bước kiểm tra bổ sung giữa Train–Validation, Train–Test và Validation–Test sẽ giúp cung cấp bằng chứng rõ ràng hơn về khả năng không có trùng lặp giữa các tập dữ liệu.

Tài liệu

- [1] Dat Quoc Nguyen and Anh Tuan Nguyen. PhoBERT: Pre-trained language models for Vietnamese. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: Findings*, pages 1037–1042, 2020.
- [2] Ashish Vaswani et al. Attention Is All You Need. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [3] Jacob Devlin et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019.
- [4] Tho Duc Nguyen et al. JointCapPunc: Joint Capitalization and Punctuation Restoration for Vietnamese Speech Recognition. *GitHub Repository*: <https://github.com/ductho9799/JointCapPunc>, Commit ee258cae, 2021.
- [5] Alec Radford et al. Robust Speech Recognition via Large-Scale Weak Supervision. In *International Conference on Machine Learning (ICML)*, 2023.
- [6] Mike Schuster and Kuldip K Paliwal. Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing*, 45(11):2673–2681, 1997.
- [7] Thomas Wolf et al. Transformers: State-of-the-Art Natural Language Processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45, 2020.