

Nghiên cứu và xây dựng hệ thống khôi phục dấu câu tiếng Việt

So sánh BiLSTM và PhoBERT cho bài toán khôi phục dấu câu tiếng Việt

Nguyễn Quang Sang Đỗ Khắc Phúc Thịnh Trần Bùi Hà Giang

Viện Trí tuệ Nhân tạo – Trường Đại học Công nghệ, ĐHQGHN

Tháng 08 năm 2026

Mạch trình bày



Luồng chính

Dữ liệu được chuẩn hóa trước khi đưa vào mô hình. Bốn cấu hình được huấn luyện và so sánh trên tập validation. Mô hình tốt nhất sau đó được đánh giá trên tập test và đưa vào demo

Bài toán: văn bản tiếng Việt thiếu dấu câu

Ví dụ đầu vào

bạn đã hoàn thành bài tập chưa ngày
mai chúng ta nộp bài

Ảnh hưởng

- Khó xác định ranh giới câu
- Mất dấu phẩy, dấu chấm và dấu hỏi
- Làm giảm khả năng đọc và xử lý văn bản

Văn bản chưa có dấu câu



Mô hình dự đoán nhãn



Văn bản đã khôi phục dấu

Mục tiêu và phạm vi

- ❶ Khôi phục ba dấu câu: phẩy, chấm, hỏi
- ❷ Gán một nhãn dấu câu cho từng từ
- ❸ So sánh BiLSTM và PhoBERT
- ❹ Thử hai cách tăng trọng số cho lớp ít xuất hiện
- ❺ Chọn mô hình bằng Punctuation Macro-F1 trên validation
- ❻ Đưa mô hình vào giao diện Streamlit

Phạm vi

Đầu vào là văn bản tiếng Việt có dấu thanh nhưng chưa có dấu câu.

Đánh giá

Các thí nghiệm được thực hiện trên JointCapPunc với ba tập: train, validation và test.

Luồng hoạt động của hệ thống



Cách hoạt động

Người dùng nhập văn bản chưa có dấu câu. Văn bản được chuẩn hóa, chia đoạn và đưa vào PhoBERT E2. Mô hình dự đoán nhãn sau từng từ; chương trình sau đó chèn dấu, chuẩn hóa khoảng trắng và viết hoa

Ví dụ đầu vào và đầu ra

Input

bạn đã hoàn thành bài tập chưa
ngày mai chúng ta nộp bài

dự đoán nhãn



Output

Bạn đã hoàn thành bài tập chưa? Ngày
mai chúng ta nộp bài.

- “chưa” → QUESTION
- “bài” cuối → PERIOD
- Từ đầu câu mới được viết hoa

Mô hình dự đoán dấu câu sau từng từ, không sinh lại toàn bộ câu

Bước 1 – Biểu diễn bài toán

Với chuỗi từ chưa có dấu câu:

$$X = (x_1, x_2, \dots, x_N)$$

mô hình dự đoán một chuỗi nhãn có cùng độ dài:

$$Y = (y_1, y_2, \dots, y_N), \quad y_i \in \{O, \text{COMMA}, \text{PERIOD}, \text{QUESTION}\}$$


Từ	bạn	xong	chưa	ngày	mai
Nhãn	O	O	QUESTION	O	PERIOD

Bốn nhãn sử dụng

O: không có dấu câu; **COMMA**: dấu phẩy; **PERIOD**: dấu chấm; **QUESTION**: dấu hỏi.

Bước 2 – Chuẩn hóa dữ liệu JointCapPunc

- ❶ Đọc dữ liệu TSV gồm từ và các nhãn tương ứng
- ❷ Chuẩn hóa ký tự tiếng Việt về dạng Unicode NFC
- ❸ Giữ nguyên dấu thanh và cấu trúc từ
- ❹ Đổi nhãn QMARK thành QUESTION
- ❺ Loại các mẫu trùng hoàn toàn trong từng tập dữ liệu



Lưu ý

Các mẫu trùng giữa train, validation và test cần được kiểm tra để hạn chế dữ liệu đánh giá xuất hiện trong tập huấn luyện

Bước 3 – Chia dữ liệu thành các đoạn

Cách chia đoạn

- 1 Mỗi đoạn tối đa 150 từ
- 2 Ưu tiên cắt tại vị trí kết thúc câu
- 3 Nếu không có vị trí phù hợp, cắt tại giới hạn
- 4 Luôn giữ từ và nhãn tương ứng với nhau

Chuỗi dài → nhiều đoạn



Giới hạn

150 từ không đồng nghĩa với 150 subword của PhoBERT, vì một từ có thể được tách thành nhiều subword. Do đó cần kiểm tra lại độ dài sau khi PhoBERT tách từ thành các phần nhỏ

Bước 4 – Căn chỉnh nhãn với PhoBERT

PhoBERT có thể tách một từ thành nhiều phần nhỏ. Trong khi đó dữ liệu chỉ có một nhãn đầu câu cho mỗi từ. Vì vậy nhóm gán nhãn thật cho phần cuối của từ

Ví dụ

Từ: hoàn_thành

Sau khi tách: hoàn | thành

Nhãn dùng khi train: -100 | PERIOD

Cách xử lý

- Phần đầu và giữa của từ: -100
- Phần cuối của từ: nhận nhãn thật
- Vị trí -100 không được tính vào loss

Mục đích

Mỗi từ chỉ được tính một lần khi huấn luyện, tránh để từ bị tách thành nhiều phần có ảnh hưởng lớn hơn các từ khác

Dữ liệu sau tiền xử lý: gần 9,9 triệu token

Split	Samples	Tokens	O	COMMA	PERIOD	QUESTION
Train	38,066	4,940,478	91.10%	4.62%	3.73%	0.56%
Validation	15,227	1,977,406	91.06%	4.64%	3.74%	0.56%
Test	22,832	2,968,815	91.04%	4.64%	3.76%	0.56%

38,066

mẫu train

4.94M

token train

0.56%

QUESTION

Phân bố nhãn giữa ba tập gần giống nhau. Lớp O chiếm hơn 91%, trong khi QUESTION chỉ khoảng 0.56%.

Lựa chọn chỉ số đánh giá

Hạn chế của Accuracy

Khoảng 91% token thuộc lớp **O**. Nếu mô hình dự đoán toàn bộ là **O**, Accuracy vẫn gần 91%, nhưng không khôi phục được dấu câu

Chỉ số chính

$$\text{Punct-Macro-F1} = \frac{F1_{\text{COMMA}} + F1_{\text{PERIOD}} + F1_{\text{QUESTION}}}{3}$$

Chỉ tính ba nhãn dấu câu: COMMA, PERIOD, QUESTION;
không tính lớp O

91.1%
nhãn O

dấu câu
khoảng 8.9%

E1 – BiLSTM



Cách hoạt động

BiLSTM đọc ngữ cảnh theo cả hai chiều. Hai trạng thái được ghép lại để dự đoán nhãn cho từng từ


Vai trò

E1 là mô hình cơ sở, huấn luyện từ đầu và có kích thước 16.9 MB. Kết quả E1 được dùng làm mốc so sánh với PhoBERT

Cách hoạt động

PhoBERT tạo biểu diễn cho mỗi phần của từ dựa trên ngữ cảnh xung quanh. Nhờ đã được tiền huấn luyện trên tiếng Việt, mô hình có sẵn kiến thức ngôn ngữ trước khi học bài toán dấu câu

- Mô hình: **PhoBERT-base-v2**
- Đầu ra: 4 nhãn dấu câu
- Độ dài tối đa: 192 subwords
- Checkpoint: 514.7 MB



Bốn thí nghiệm E1–E4

Mã	Kiến trúc	Trọng số lớp	Mục đích
E1	BiLSTM	Không	Mô hình cơ sở
E2	PhoBERT	Không	PhoBERT thông thường
E3	PhoBERT	Full inverse	Tăng mạnh trọng số lớp hiếm
E4	PhoBERT	Sqrt inverse	Tăng vừa phải lớp hiếm

Mục đích so sánh

QUESTION chỉ chiếm khoảng 0.56%. E3 và E4 kiểm tra việc tăng trọng số lớp hiếm có giúp mô hình nhận biết dấu câu tốt hơn hay không

Trọng số lớp trong E3 và E4

E3 – Full inverse

$$w_c = \frac{N_{total}}{K N_c}$$

Lớp càng ít xuất hiện thì trọng số càng lớn

E4 – Sqrt inverse

$$w_c = \sqrt{\frac{N_{total}}{K N_c}}$$

Dùng căn bậc hai để giảm mức chênh lệch giữa các lớp

Cách tính loss

Loss của mỗi từ được nhân với trọng số của nhãn thật. Các vị trí -100 vẫn được bỏ qua khi huấn luyện

Thiết lập huấn luyện

Siêu tham số	E1	E2	E3	E4
Max length	150 words	192 subwords	192 subwords	192 subwords
Batch hiệu dụng	128	16	16	16
Optimizer	AdamW	AdamW	AdamW	AdamW
Learning rate	10^{-3}	3×10^{-5}	3×10^{-5}	3×10^{-5}
Weight decay	10^{-4}	0.01	0.01	0.01
Warmup ratio	–	0.10	0.10	0.10
Epoch	12	5	5	5


Lưu mô hình

Sau mỗi epoch, mô hình được đánh giá trên validation. Chỉ checkpoint có Punctuation Macro-F1 cao nhất được giữ lại

Lưu ý

E2–E4 đạt kết quả tốt nhất ở epoch 5, cũng là epoch cuối. Do đó chưa thể khẳng định mô hình đã hội tụ hoàn toàn


Quy trình chọn mô hình



Nguyên tắc đánh giá

Mô hình được chọn hoàn toàn bằng validation. Tập test chỉ được sử dụng sau khi E2 đã được cố định

Kết quả validation: E2 đạt cao nhất




Validation Punct-F1

- **E2: 0.7787**
- E4: 0.7457
- E3: 0.6953
- E1: 0.6282

Kết quả

E2 đạt điểm cao nhất. Hai cách tăng trọng số lớp hiếm không cải thiện kết quả tổng thể

Ảnh hưởng của trọng số lớp



Nhận xét

E2 đạt F1 cao nhất ở cả COMMA, PERIOD và QUESTION. E3 giảm mạnh ở COMMA; E4 tốt hơn E3 nhưng vẫn thấp hơn E2

Kết quả E2 trên tập test


0.7763

Punctuation Macro-F1

0.9663

Accuracy



Nhãn	Precision	Recall	F1
COMMA	0.7407	0.7054	0.7226
PERIOD	0.7948	0.8240	0.8091
QUESTION	0.7484	0.8528	0.7972



Nhận xét

Kết quả validation và test gần nhau. COMMA là nhãn có F1 thấp nhất

So sánh bổ sung các mô hình trên tập test





Kết quả

E2 đã được chọn bằng validation trước bước này. Trên tập test, E2 đạt 0.7763, cao hơn E1 BiLSTM với 0.6246. Kết quả test của các mô hình còn lại chỉ dùng để so sánh bổ sung

Phân tích lỗi bằng ma trận nhầm lẫn

Official test confusion matrix — winner E2



- 70.5% COMMA được dự đoán đúng ; 20.0% bị dự đoán thành O
- 8.7% COMMA bị nhầm thành PERIOD
- PERIOD đúng 82.4%; QUESTION đúng 85.3%

Hậu xử lý và demo

Một số lỗi thường gặp

- COMMA → O: bỏ sót dấu phẩy
- QUESTION → PERIOD: nhầm dấu hỏi thành dấu chấm
- O → QUESTION: thêm dấu hỏi không cần thiết

Hậu xử lý

- 1 Chèn dấu sau từ
- 2 Chuẩn hóa khoảng trắng
- 3 Viết hoa đầu câu
- 4 Giữ nguyên URL, email và số thập phân

Giao diện demo

Streamlit đọc `model_selection.json` để xác định và tải mô hình đã chọn. Người dùng nhập văn bản chưa có dấu câu và nhận lại văn bản đã được khôi phục dấu câu

Kết luận và hướng phát triển

Kết quả chính

- Hoàn chỉnh pipeline dữ liệu → mô hình → hậu xử lý → demo
- E2 đạt Punctuation Macro-F1 = **0.7763** trên tập test
- PhoBERT đạt kết quả cao hơn BiLSTM trong thí nghiệm
- Kết quả validation và test gần nhau

Hướng phát triển

- ➊ Mở rộng đầu vào audio bằng ASR, ví dụ Whisper
- ➋ Kết hợp dự đoán viết hoa và dấu câu
- ➌ Tiếp tục cải thiện xử lý văn bản dài
- ➍ Đánh giá trên thêm các nguồn dữ liệu khác

Cảm ơn thầy và các bạn!

Q&A